

SONORA DIGITAL CORP

Guia Completa del Sistema

Arquitectura, pipeline de voz, llamadas masivas, inteligencia del prospecto, paquetes de pricing, sistema multi-nicho, swarm agents, MCPs, seguridad, tokenomics y medicion. Todo explicado a traves de situaciones humanas reales.

El Pipeline de Voz Completo

Imagina esto: **Roberto** es contador en Hermosillo. Tiene un despacho chico, 3 empleados, y pierde 15 clientes al mes porque nadie contesta el telefono despues de las 6pm. Roberto no sabe nada de IA. Solo sabe que su competencia tiene "un robot que atiende" y el quiere uno tambien. Voy a explicarte **cada milisegundo** de lo que pasa cuando un prospecto llama, desde tres perspectivas diferentes: el externo (quien llama), el consumidor (tu cliente), y el creador (tu, Mystic).

Perspectiva del Externo: Maria Llama

Maria acaba de googlear "contador en Hermosillo para declaracion anual". Ve un anuncio de Roberto. Marca el numero. A continuacion te explico exactamente que sucede en cada etapa del camino.

- 1 **La senal sale de su telefono** — El telefono de Maria conecta con la antena de Telcel, viaja por la red telefonica publica (PSTN), y llega a tu VPS OVH. Tu VPS tiene un **numero de telefono virtual** (DID number) comprado por aproximadamente \$2 USD/mes a traves de proveedores como Vonage o Twilio. Ese numero esta conectado a tu VPS por un protocolo llamado **SIP** (Session Initiation Protocol), que es esencialmente el "idioma" que hablan los telefonos por internet. Es como una linea telefonica digital que vive en tu servidor.
- 2 **FreeSWITCH contesta (0.3 segundos)** — FreeSWITCH es el "repcionista telefonico" que vive en tu VPS. Es un software 100% libre y open source que maneja llamadas telefonicas. Piensa en el como la central telefonica de una oficina grande, pero completamente digital. En este momento, FreeSWITCH hace tres cosas simultaneamente: (a) contesta la llamada, (b) identifica que numero fue marcado y a que tenant pertenece, y (c) busca en la base de datos si ese numero esta registrado como cliente activo. Todo esto ocurre en menos de medio segundo.
- 3 **El audio viaja a Whisper (NO al LLM aun)** — Este es el paso mas critico y el que tu Planeacion Maestra original no cubria. Maria dice: "Hola, buenas tardes, quisiera informacion sobre sus servicios de contabilidad..." Ese audio **NO va directo al LLM** (ChatGPT, Claude, etc.). Primero pasa por tres filtros secuenciales que miden, analizan y contextualizan antes de que cualquier modelo de lenguaje intervenga.

FILTRO 1 — Whisper (Transcripcion): Convierte la voz de Maria a texto. "Hola, buenas tardes, quisiera informacion sobre sus servicios de contabilidad para mi negocio." Tiempo: ~0.8 segundos. Modelo: whisper-large-v3, 100% open source, corre en tu VPS.

FILTRO 2 — Medicion de Energia (Sentiment + Tone): Aqui se mide todo lo que pediste. Velocidad de habla (rapida = urgencia), tono (agudo = estres, grave = confianza), volumen (alto = enojo, bajo = timidez), pausas (muchas = duda), sentimiento (positivo, neutral, negativo). Herramientas: VAD (Voice Activity Detection), Silero VAD (open source), y modelos como wav2vec2 para deteccion de emocion. Tiempo: ~0.3 segundos.

FILTRO 3 — Context Retriever (Memoria): El sistema busca en la base de datos: "Maria ha llamado antes? Tiene cita? Es lead?" Si es primera vez, se etiqueta como NEW_LEAD. Si ha llamado antes, carga TODO el historial. Tiempo: ~0.2 segundos usando Redis cache.

- 4 **El Orquestador decide que agente atiende** — Ahora SI entra el LLM, pero NO como piensas. El Orquestador (Mystic Core) es un programa Python que no "piensa" sino que **toma decisiones basadas en reglas + ML**. Regla 1: Es lead nuevo o recurrente? Nuevo va a Recepcionista. Regla 2: Cual es el temperamento? Alta energia + positivo = Vendedor modo warm. Regla 3: Que pide? Informacion = calificar. Precio = Vendedor. Queja = Soporte. En el caso de Maria: nueva lead, tono curioso, pide informacion, entonces el agente asignado es **La Guardiana (Recepcionista)** en modo educativo + calificacion.
- 5 **El LLM genera la respuesta** — El Orquestador envia al LLM (Claude via OpenRouter) un system prompt que incluye la personalidad del agente, el contexto del prospecto, las medidas de energia detectadas, y las reglas de marca. El LLM genera la respuesta textual. Tiempo: ~1.5 segundos. Costo: ~\$0.003 USD por interaccion. La respuesta se genera respetando siempre la filosofia de no manipulacion y empoderamiento.
- 6 **Kokoro convierte texto a voz** — La respuesta textual se convierte a audio usando Kokoro TTS, 100% open source. La voz se clona a partir de una grabacion de 30 segundos del cliente. La velocidad y el tono se ajustan al temperamento del prospecto: si Maria esta tranquila, la voz es tranquila; si tiene urgencia, la voz es mas energetica. Tiempo: ~0.5 segundos.
- 7 **FreeSWITCH envia la voz de vuelta a Maria** — El audio viaja: Kokoro a FreeSWITCH, FreeSWITCH a SIP, SIP a PSTN, PSTN al telefono de Maria. **Latencia total: ~3.5 segundos** (un humano responde en 1-2 segundos). La meta es reducir esto a menos de 2.5 segundos.

Diagrama completo del pipeline

```
MARIA HABLA
|
v
[TELEFONO] → [ANTENA] → [PSTN / RED TELEFONICA]
|
v
[NUMERO DID VIRTUAL] ← Vonage/Twilio ~$2/mes
|
v
[FREESWITCH] ← Tu central telefonica en el VPS
| - Identifica tenant
| - Identifica caller ID
| - Busca historial en Redis
v
[WHISPER] ← Voz a texto (~0.8s)
|
v
[ANALIZADOR DE ENERGIA] ← VAD, Silero, wav2vec2
| Resultado: {energy: alta, tone: curiosa...}
v
[CONTEXT RETRIEVER] ← Busca en BD (~0.2s)
|
v
[ORQUESTADOR] ← Decide por reglas
|
v
[LLM: Claude/GPT/DeepSeek] ← Genera respuesta (~1.5s)
|
v
[KOKORO TTS] ← Texto a voz clonada (~0.5s)
|
v
[FREESWITCH] → [SIP] → [PSTN] → [TELEFONO]
|
v
MARIA ESCUCHA → RESPONDE → CICLO SE REPITE
```

Perspectiva del Consumidor: Roberto en su Dashboard

VISTA DEL CLIENTE — Roberto (Contador)

Roberto se levanta a las 7am. Abre su dashboard (pagina web). Ve: 12 llamadas atendidas, 3 citas agendadas, 8 leads nuevos. Puede escuchar cualquier llamada en vivo o grabada, ver la transcripcion en tiempo real, y observar el temperamento de cada prospecto con iconos (cara feliz, neutral, preocupada). Recibe resumen automatico post-llamada generado por IA. Recibe alertas por Telegram: "Tu agente agendo una cita con un lead caliente." Roberto no necesita saber nada de tecnologia.

Perspectiva del Creador: Mystic en su Panel

VISTA DEL CREADOR — Mystic (Tu)

Tu ves TODO: cada tenant activo (14), cada agente corriendo (47 instancias), tokens gastados hoy (\$23.40 USD), alertas (2 pendientes). Ves latencia promedio por tenant, costos por componente (OpenRouter, Kokoro, Whisper, VPS), llamadas atendidas vs fallidas. Si algo falla, recibes alerta por Telegram antes de que el cliente se de cuenta. Control total del sistema con visibilidad completa.

CAPITULO 2

Llamadas Masivas Outbound

Imagina que tienes 200 numeros de prospectos y necesitas llamar a 50 personas al mismo tiempo. No puedes llamar uno por uno. El sistema necesita un **ejercito de voces que llame por ti**, pero con contexto, inteligencia y personalizacion para cada prospecto.

Paso 1: El cliente sube su lista

Roberto sube un CSV a su dashboard con columnas: nombre, telefono, negocio, sitio web. O le dice a su agente por voz: "Busca todos los negocios de contabilidad en Hermosillo que no tienen pagina web y llamalos." El sistema genera la lista automaticamente.

Paso 2: Inteligencia del Prospecto (antes de llamar)

ESTO ES LO QUE TU DOCUMENTO ORIGINAL NO TENIA Y ES CLAVE. Antes de marcar, el sistema investiga al prospecto de forma automatizada usando workers paralelos en Celery + Redis (~30 seg por prospecto).

Buscador 1: Google Business (Playwright)

Calificacion en estrellas, resenas recientes, fotos, horarios, si responden mensajes. Cada dato es una oportunidad de venta o contexto para personalizar la llamada.

Buscador 2: Pagina Web (Playwright + BeautifulSoup)

Si tiene web, si es responsive, velocidad de carga, WhatsApp flotante, boton de reserva, blog, fecha de ultima actualizacion. Cada deficiencia = oportunidad.

Buscador 3: Redes Sociales

Instagram, Facebook, TikTok. Seguidores, frecuencia de publicacion, tipo de contenido. Si publican mucho pero no tienen atencion automatizada = oportunidad.

Buscador 4: Analisis de Competencia

3 competidores principales, servicios que el prospecto NO tiene, precios del mercado. Data que alimenta el script de llamada personalizado.

Paso 3: Calificacion automatica (1-100)

Con la data recolectada, el sistema asigna un **Puntaje de Oportunidad**: sin WhatsApp (+15), web no responsive (+20), no responde mensajes (+15), competencia mejor (+10), calificacion baja (+10), sin boton de reserva (+15), negocio activo (+10). Los mejores puntajes se llaman primero.

Paso 4: Llamada con contexto enriquecido

El agente SABE todo sobre el prospecto: "Hola Maria, vi que Ropa Lindo tiene una web que no se ve en celular. Sabias que el 78% de tus clientes te buscan desde su telefono?" Si hay interes, el sistema envia automaticamente por WhatsApp: video demo, fotos de ejemplos, diapositiva antes/despues, link a landing page, nota de voz. Todo se dispara al detectar interes.

Paso 5: Mapa de llamadas en tiempo real

Mientras 50 llamadas ocurren simultaneamente, tu ves: nombre del prospecto, temperatura (caliente/tibio/frio), duracion, estado (en curso, conectada, no contesto, buzón). Seccion de inteligencia acumulada: patrones detectados, mejor horario de contacto, objeciones mas comunes, tasa de interes, citas agendadas. Control total del ejercito.

CAPITULO 3

Los 3 Paquetes de Pricing

No vendas herramientas, vende transformacion. No se pone el precio rapido. Se empieza con freemium y se escala. El precio es dinamico: no es el mismo para alguien personal que para una empresa. El onboarding es diferente para cada tipo de humano.

Situacion real: Ana tiene reposteria en casa, sin marca, gana 8,000MXN/mes. *Carlos tiene clinica dental con 3 sucursales, 12 empleados, 500,000 MXN/mes.* Deberian pagar lo mismo? No. El sistema detecta y adapta.

Despertar

"Para el humano que empieza a despertar su presencia digital"

GRATIS 14 dias → \$299 MXN/mes

~\$17 USD/mes · Margen: 70% · Objetivo: HOOK

- **1 Agente de voz** (Recepcionista)
- **1 canal** (WhatsApp o Telegram)
- **100 llamadas/mes**
- Dashboard basico con transcripcion automatica
- 1 numero de telefono virtual
- Resumen diario por WhatsApp
- Reporte semanal por email

Elevar

"Para el negocio que quiere que su presencia digital trabaje mientras duerme"

\$1,499 MXN/mes

~\$89 USD/mes · Margen: 50% · Objetivo: CASH COW

- **3 Agentes de voz:** Recepcionista, Vendedor, Soporte
- **3 canales:** WhatsApp + Telegram + Llamadas
- **500 llamadas/mes**
- Dashboard avanzado con metricas en tiempo real
- Embudo de ventas automatizado (Cold → Warm → Hot)
- Inteligencia del prospecto (scraping web completo)
- 3 numeros de telefono virtual
- Campanas outbound (el sistema llama por ti)
- Content factory (30 piezas/mes de marketing)
- Clonacion de voz profesional
- Reportes semanales + alertas en tiempo real
- Soporte prioritario por WhatsApp

Soberano

"Para la empresa que quiere su propio reino digital completo"

CUSTOM (Cotizar)

5,000—50,000+ MXN/mes · Setup: \$10,000 MXN · Objetivo: ANCLA

- **Todo lo de Elevar** mas: Agentes ilimitados, Llamadas ilimitadas, Canales ilimitados
- Dashboard 3D "Hogar del Agente" (tipo JARVIS: voz + visuales + movimiento)
- Inteligencia profunda del prospecto (análisis de toda su presencia digital)
- Embudos personalizados ilimitados
- Clonación de voz + imagen + 3D
- Swarm agents (coordinación multi-agente)
- API dedicada (conecta tu propio software)
- White-label (tu marca, no la nuestra)
- Training custom, SLA 99.9%, Account manager dedicado

Onboarding Especial: Nicho OnlyFans/NSFW

El nicho de OnlyFans requiere onboarding único: el sistema mide al creador (nivel de contenido, frecuencia, tipo de interacción, tono preferido), realiza clonación avanzada de voz con tonos múltiples y clon de imagen. El agente aprende la personalidad del creador y genera DMs personalizados, mensajes de cumpleaños, promociones. Todo con consentimiento explícito y aprobación del creador antes de publicar.

Tabla Comparativa

Feature	Despertar	Elevar	Soberano
Agentes	1	3	Ilimitados
Llamadas/mes	100	500	Ilimitadas
Dashboard	Basico	Avanzado	3D Jarvis
Inteligencia	No	Basica	Profunda
Embudos	No	1	Ilimitados
Clon Voz+Img	No	Voz	Voz+Img+3D
Swarm Agents	No	No	Si
White-label	No	No	Si
Soporte	Email	WhatsApp	Dedicado
Precio	\$299	\$1,499	Custom
Costo real	~\$5 USD	~\$25 USD	~\$100+ USD
Margen	70%	50%	40-60%

CAPITULO 4

Sistema Multi-Nicho

La vision: **agentes que saben exactamente que decirle a un contador, a un restaurantero, a un creador de OnlyFans**. Roberto (contador) y Don Felipe (restaurante) contratan el mismo sistema pero ven cosas completamente diferentes.

Roberto (Contador)

Dashboard azul profesional. Agentes: "Recepcionista Contable" (ISR, declaraciones, facturas), "Agente Vendedor" (paquetes contables), "Agente Soporte" (facturas, SAT). Terminologia adaptada: "Leads" = "Prospectos fiscales", "Ventas" = "Contratos firmados". Knowledge base: ISR 2026, IETU, IVA, fechas de declaracion, servicios y precios de Roberto.

Don Felipe (Restaurante)

Dashboard calido naranja. Agentes: "Recepcionista Gastronomica" (menu, precios, reservas), "Agente Reservas" (agenda mesas), "Agente Pedidos" (domicilio). Terminologia: "Leads" = "Comensales", "Ventas" = "Pedidos confirmados". Knowledge base: menu, ingredientes, alergenos, horarios, zona de entrega, promociones.

Base de Conocimiento por Nicho (3 carpetas)

Cada nicho tiene: **(1) Knowledge Base** (información del sector: leyes, regulaciones, tendencias, jerga), **(2) Client Profile** (datos del cliente: servicios, precios, políticas, FAQ), y **(3) Objections Handbook** (como manejar objeciones específicas del nicho con ejemplos de respuestas empoderadoras, nunca manipuladoras).

CAPITULO 5

Swarm Agents y 23 MCPs

Un **swarm de agentes** es como una colmena: multiples agentes con roles especificos trabajando juntos, coordinados por un cerebro central. El cliente escucha una sola voz y no sabe que hay multiples agentes detras.

Ejemplo: Un cliente pide reserva para 20 + menu niños + catering. El Recepcionista detecta complejidad alta y deriva al Agente Catering (cotizacion) y al Agente Reservas (agenda mesa). El Coordinador une todo. Al final, WhatsApp con confirmacion + cotizacion. Todo automatico.

Los 23 MCPs organizados por categoria

#	MCP	Funcion	Open Source
BASE DE DATOS (4)			
1	supabase-mcp	Datos del negocio	Si
2	neo4j-mcp	Relaciones entre datos	Si
3	qdrant-mcp	Busqueda semantica	Si
4	redis-mcp	Cache y sesiones	Si
VOZ (3)			
5	whisper-mcp	Audio a texto (STT)	Si
6	kokoro-mcp	Texto a voz clonada (TTS)	Si
7	freeswitch-mcp	Telefonia SIP	Si
COMUNICACION (4)			
8	telegram-mcp	Mensajes Telegram	Si
9	whatsapp-mcp	Mensajes WhatsApp	Parcial
10	email-mcp	Email transaccional	Si
11	instagram-mcp	DMs y contenido	No
INTELIGENCIA (5)			
12	scraper-mcp	Web scraping	Si

13	google-mcp	Busqueda Google	Si
14	vision-mcp	Generacion de video	No
15	sentiment-mcp	Sentimiento y emocion	Si
16	enrich-mcp	Enriquecimiento de data	Si
PAGOS Y NEGOCIO (3)			
17	mercadopago-mcp	Cobros y suscripciones	No
18	calendar-mcp	Agenda	Si
19	crm-mcp	Gestion de leads	Si
SISTEMA INTERNO (4)			
20	agent-registry-mcp	Registro de agentes	Si
21	token-mcp	Economía SON	Si
22	monitoring-mcp	Alertas y metricas	Si
23	evolution-mcp	Auto-mejora prompts	Si

Total: 23 MCPs | 18 open source (78%) | 5 propietarios. Meta 90% open source cumplida.

CAPITULO 6

Arboles de Medicion

Lo que no se mide, no existe. Cada area tiene su arbol con umbrales que generan alertas automaticas.

Arbol: Agente Recepcionista

RECEPCIONISTA RENDIMIENTO Llamadas atendidas (meta: 95%+) Tiempo de respuesta (meta: <3 seg) Duracion promedio (meta: 2-5 min) Tasa de abandono (meta: <5%) **CALIDAD** Empatía detectada (meta: >80%) Uso de jerga del nicho (meta: >70%) Sin FOMO toxico (meta: 100%) BANT completado (meta: >85%) **IMPACTO NEGOCIO** Leads calificados generados Conversion lead → cita (meta: >30%) Revenue atribuido **TECNICO** Latencia total (meta: <2.5s) Costo por llamada (meta: <\$0.05) Uptime (meta: 99.9%)

Arbol: Embudo Cold Call

FUNNEL COLD CALL ENTRADA Total prospectos, data enriquecida, puntaje promedio **CONTACTO** Llamadas completadas, tasa contacto (meta: >40%) **CALIFICACION** BANT completado, tasa calificacion (meta: >25%) **CONVERSION** Citas agendadas, tasa cierre (meta: >15%) **FINANCIERO** Costo por lead, revenue total, ROI (meta: >5x)

Arbol: Infraestructura

INFRAESTRUCTURA RECURSOS VPS CPU (meta: <60%), RAM (meta: <70%), Disco (meta: <80%) LATENCIA Whisper <1s, LLM <1.5s, Kokoro <0.5s, Pipeline <2.5s COSTOS OpenRouter, TTS, STT, VPS (diario/semanal/mensual) ALERTAS CPU>80%, RAM>85%, Latencia>5s, Budget>150%

CAPITULO 7

Plan Anti-Pirateria (6 Capas)

Tu "receta" (prompts, knowledge bases, motor de medicion) es tu propiedad intelectual mas valiosa. Si alguien copia tu codigo pero no tus prompts, no puede replicar tu producto.

Capa	Proteccion
1. Infraestructura	Firewall UFW, Fail2ban, WireGuard VPN, Nginx WAF, rate limiting, SSL
2. Aplicacion	API Keys en Vault, JWT 1h exp, Row Level Security, input sanitization, CORS
3. Prompts	Encriptados en DB, solo Orquestador descripta, version control, Prompt Vault
4. Modelos	Container Docker aislado por tenant, archivos encriptados, borrado criptografico
5. Codigo	Open Core: framework open source (AGPL-3.0), prompts y nicho KB son propietarios
6. Anti-Reverse	Rutas ofuscadas, respuestas sanitizadas, monitoreo anomalias, honeypots

CAPITULO 8

Alertas, Cron Jobs y Evolution Engine

Niveles de Alerta (Telegram)

INFO (cada hora)
Resumen: llamadas, citas, costo, latencia.

WARNING (inmediato)
Latencia subio, anomalia detectada.

CRITICAL (inmediato + SMS)
Agente caido, llamadas sin contestar.

BUDGET (diario)

Gasto vs limite, tenant mas costoso.

VENTA (inmediato)

Venta cerrada, nuevo cliente, upgrade.

Cron Jobs

Frecuencia	Tarea
Cada minuto	Verificar agentes online, latencia <3s
Cada 5 min	Cola emails, WhatsApp seguimiento leads warm
Cada hora	Metricas, rotar API keys, limpiar cache
Cada dia (6am)	Reporte clientes, scraper prospectos, contenido redes, prompt evals, verificar backups
Cada semana	Reporte semanal, A/B testing, actualizar KB, limpiar logs
Cada luna llena	Burn tokens, lanzar feature, publicar Ritual Digital

Evolution Engine: Auto-mejora

(1) Recopilacion: cada llamada se guarda con metadata completa. **(2) Analisis:** cada noche, identifica patrones de exito y fracaso. **(3) Propuesta:** si detecta un fallo repetido, genera mejora de prompt y la envia a Mystic via Telegram para aprobacion. **(4) A/B Test:** si se aprueba, se prueba en 20% de llamadas. Si funciona mejor, se expande al 100%. **(5) Itera:** los resultados se miden y el ciclo continua. No es magia: es Medir, Analizar, Proponer, Probar, Iterar.

CAPITULO 9

Variables de Entorno

Hay 3 niveles: globales (compartidas), por agente (especificas del rol), y por tenant (aislan a cada cliente). Cada nivel tiene sus variables propias que controlan el comportamiento, la seguridad y la medicion.

Tokenomics por Paquete

Accion	Despertar	Elevar	Soberano
Llamada atendida	1 SON	2 SON	3 SON
Lead capturado	5 SON	10 SON	15 SON
Venta cerrada	-	50 SON	100 SON
Onboarding	20 SON	30 SON	50 SON
Referir	50 SON	75 SON	100 SON
Pago en SON	10% desc.	10% desc.	10% desc.

CAPITULO 10

Analogia: El Restaurante Mistico

Componente	Equivalente	Que hace
VPS OVH	El edificio	Lugar fisico donde todo ocurre
FreeSWITCH+Whisper+Kokoro	La cocina	Voz entra cruda, se cocina, sale lista
LLM (Claude)	El chef	Toma ingredientes, crea platillo perfecto
Knowledge Base	El menu	Sabe que hacer segun el tipo de restaurante
El Agente	El mesero	Interactua con el cliente
Multi-tenant	Mesas separadas	Nadie ve lo que come el otro
Orquestador	El gerente	Decide que mesero atiende que mesa
Tokenomics	El cajero	Cada transaccion se mide en SON
Prometheus+Grafana	Las camaras	Si algo se quema, suena la alarma
Evolution Engine	Libro de quejas	Si muchos se quejan, cambia la receta
3 Paquetes	La carta	Carta, Menu del día, Banquete

CAPITULO 11

Flujo Humano: De TikTok a Cliente

Anna (mecanica) ve tu TikTok. Te manda WhatsApp. En 72 horas, tiene un agente atendiendo sus clientes. Dia 1: Descubrimiento (onboarding adaptado en landing, sube audio, elige plan Despertar GRATIS). Dia 2: Activacion (sistema clona voz, crea KB de mecanica, entrena agente, WhatsApp de bienvenida). Dias 3-14: Periodo gratuito (agente atiende ~5 llamadas/día, reportes nocturnos por WhatsApp). Dia 15: Conversion. Meses despues: Ana sube a Elevar, luego Soberano, refiere amigos, gana tokens. **Este es el ciclo de vida de tu cliente.**

El LLM no es el producto. Tu producto es el sistema completo que conecta telefonía, voz, inteligencia, personalización y medición. Tu no vendes agentes de IA. Vendes que tu negocio nunca duerme.

"El LLM no es el producto. El LLM es una pieza del pipeline. Tu producto es el sistema completo que conecta telefonía, voz, inteligencia, personalización y medición."

MYSTIC · SONORA DIGITAL CORP

Julio 2026 · Version 2.0